



**Data Science
Academy**

www.datascienceacademy.com.br

**Microsoft Power BI Para Data Science,
Versão 2.0**

**Mini-Projeto 3
Publicação do Modelo com o Power BI**



O conteúdo deste capítulo ficou com uma quantidade de conteúdo bem superior ao inicialmente estabelecido para este curso gratuito. Por conta disso vamos encerrar este projeto apenas com um overview da publicação do modelo de Machine Learning. Caso deseje aprender como realizar o procedimento em detalhes, os demais cursos e formações da DSA estão à sua disposição.

O link abaixo também apresenta alguns detalhes de como fazer a publicação do modelo com o Power BI e você pode usar o conhecimento adquirido neste capítulo e estudar o processo de publicação, se desejar:

<https://powerbi.microsoft.com/pt-br/blog/power-bi-azure-ml/>

O Azure ML é estudado no primeiro curso da Formação Cientista de Dados e outros assuntos ligados ao tema são estudados no curso de Power BI Avançado.

Publicar um modelo de Machine Learning significa usar o modelo para resolver o problema para o qual ele foi criado. Se o objetivo do modelo é prever o valor de casas (por exemplo), alimentamos o modelo com novos dados de entrada e o modelo gera as saídas, ou seja, as previsões.

No caso da previsão de clientes inadimplentes, alimentamos o modelo com dados de novos clientes e o modelo deverá ser capaz de prever um sim ou não, ou seja, inadimplente ou não inadimplente. Isso vale tanto para o processo feito diretamente no RStudio (como fizemos) quanto no Power BI. Mas lembre-se que o Power BI não é a ferramenta ideal para isso e apresenta diversas limitações. Azure ML e Azure Cognitive Services são outras ferramentas da Microsoft mais apropriadas para este propósito. Outra alternativa é usar o Shiny para publicar modelos criados com Linguagem R e nesse caso não usamos o Power BI. Conheça mais sobre o Shiny aqui: <https://shiny.rstudio.com>. O Shiny é estudado em vários cursos da DSA.

Um ponto de atenção é que qualquer transformação feita nos dados para o treinamento do modelo deve ser aplicada aos novos dados antes de realizar previsões com o modelo treinado. Isso pode significar a criação de um pipeline de dados para extrair os dados da fonte, aplicar as transformações e alimentar o modelo, criando assim um fluxo contínuo de operação.

A criação do modelo de Machine Learning é trabalho do **Cientista de Dados**. A criação do pipeline de dados é trabalho do **Engenheiro de Dados**. E o deploy (publicação do modelo) é trabalho do **Engenheiro de Machine Learning**.

Até o próximo capítulo!